



UNIVERSIDADE DO MINHO
Departamento de Informática

SCRIPTING NO PROCESSAMENTO DE LINGUAGEM NATURAL

Trabalho Prático 02

Realizado por:
Duarte Araújo (pg58806)

May 26, 2026
Ano Letivo 2025/26

Índice

1	Introdução	3
2	Recolha do Corpus	3
2.1	Preparação do Corpus	3
3	Retriever de documentos relevantes.....	3
3.1	Retrieval Léxico - BM25	3
3.2	Retrieval Semântico - SBERT	4
4	Extração de informação.....	4
4.1	Extractive QA	4
4.2	Abstractive QA	5
5	Conclusões	5

1 Introdução

O Trabalho Prático 2 da cadeira de Scripting no Processamento de Linguagem Natural consiste no desenvolvimento de uma *pipeline* de *information retrieval* e question answering, na qual processamos um corpus escolhido por nós acerca de um tema do nosso interesse. Devemos implementar alguma forma de extração dos documentos relevantes face a uma query, seja ela léxica, semântica ou híbrida, assim como devemos usar dois modelos para a extração e geração de respostas com base no contexto retirado dos textos constituintes do corpus.

2 Recolha do Corpus

Para este trabalho, a seleção do corpus foi atribulada, e, inicialmente, tinha sido definido um conjunto de guiões cinematográficos para o efeito, apesar de não apresentarem uma coesão temática significativa, ou informação factual para ser extraída ou inferida. Eventualmente, optei por utilizar um aglomerado de artigos variados da Wikipédia sobre a história do cinema, já que estes abrem mais oportunidades para vermos a pipeline desenvolvida a retornar resultados mais interessantes.

Foi usado um script para realizar o *fetch* das páginas, através da API pública da Wikipédia, especificando um conjunto de títulos de artigos que abordassem diferentes temas, como Hollywood clássica, pós-guerra e cinema internacional, blockbusters, animação, milestones técnicas e a indústria do cinema global, por exemplo.

2.1 Preparação do Corpus

Com a intenção de preparar os textos para a pipeline, foram criadas funções que removessem caracteres e padrões irrelevantes presentes neste tipo de artigo (relativos a formatação e *highlighting*, por exemplo), assim como minimizar a letra do texto, extrair secções com valor para scoring (como a introdução e as sugestões de outras páginas), e tokenizar o texto limpo, ignorando stopwords, para maximizar a quantidade de informação semântica a ser absorvida. Além disso, também se fez uma divisão do texto em chunks para serem analisados separadamente.

```
Total tokens in corpus: 401886
Average tokens per article: 4230.38
Total chunks in corpus: 1677
Average chunks per article: 17.65
```

```
Unique vocabulary size: 29,306
Top 30 most common tokens:
```

```
  film: 12,186
  first: 1,867
  time: 1,780
  one: 1,711
  also: 1,585
  studio: 1,568
  (...)
```

3 Retriever de documentos relevantes

3.1 Retrieval Léxico - BM25

O BM25 é um algoritmo de recolha de informação que determina a relevância de um documento face uma query. É semelhante ao TF-IDF abordado nas aulas, porém é capaz de mitigar certos problemas que este apresenta com os seus parâmetros k_1 e b , que controlam a influência da saturação dos termos e do comprimento dos documentos, respetivamente, o que leva a uma normalização dos scores obtidos.

$$Score(q, d) = \sum_{t \in q} IDF(t) \cdot TF(t, d)$$

Query: "horror shark summer blockbuster"

1. Jaws (film)	['encyclopedia']	score=10.2169
2. Steven Spielberg	['encyclopedia']	score=6.8025
3. Howard Hawks	['encyclopedia']	score=3.8722
4. Cinema of the United States	['encyclopedia']	score=3.6302
5. Cannes Film Festival	['encyclopedia']	score=3.064

Query: "samurai japanese cinema"

1. Seven Samurai	['encyclopedia']	score=7.2631
2. Akira Kurosawa	['encyclopedia']	score=6.9632
3. History of film	['encyclopedia']	score=5.4326
4. Andrei Tarkovsky	['encyclopedia']	score=5.3739
5. Pulp Fiction	['encyclopedia']	score=3.8174

Query: "History of silent film"

1. Silent film	['encyclopedia']	score=2.4466
2. Sound film	['encyclopedia']	score=2.4223
3. Harold Lloyd	['encyclopedia']	score=2.4138
4. Lillian Gish	['encyclopedia']	score=2.4068
5. Buster Keaton	['encyclopedia']	score=2.4035

3.2 Retrieval Semântico - SBERT

O modelo base utilizado, **all-MiniLM-L6-v2** é um modelo compacto e eficiente, e para realizar o seu fine-tuning foi criado um novo dataset composto por pares aleatórios de documentos, avaliados quanto à semelhança das suas listas de páginas sugeridas. Dá-se também uma normalização desse score correspondente ao número de tokens em comum às duas listas, de modo a que este se encontre entre 0 e 1. Após o split do dataset para o treino e para o teste, passamos de facto ao fine-tuning do modelo, e podemos perceber que este processo teve um impacto bastante positivo na sua performance.

Baseline Spearman correlation (before fine-tuning): 0.2647

Fine-tuned Spearman correlation: 0.8266

Improvement: +0.5620

Query = "the transition from silent movies to talking movies"

Rank	Base model	Fine-tuned
1	Silent film	Sound film
2	Sound film	Silent film
3	History of film	Ben-Hur (1959 film)
4	Cinema of the United States	Film noir
5	Lillian Gish	History of animation

4 Extração de informação

4.1 Extractive QA

Na secção de *extractive QA*, foi utilizado um modelo pré treinado no dataset SQuAD especificado no enunciado, o **deepset/roberta-base-squad2**. O modelo recebe um par (pergunta, contexto) e prevê as posições de início e fim do span de resposta no contexto. O score é calculado com a média dos logits máximos de início e fim.

Question: What caused the decline of the studio system?

Answer : many films were now being made on location in other countries or using studio facilities
 Source : History of film
 Score : 5.676449537277222
 (...)

Question: Who created the Cinématographe?

Answer :
 Source : Cannes Film Festival
 Score : 4.3904807567596436
 (...)

Question: What is film noir?

Answer : strange erotic ambivalent and cruel
 Source : Film noir
 Score : 3.0010467767715454
 (...)

4.2 Abstractive QA

Para o *abstractive QA* o modelo escolhido foi o **google/flan-t5-base**. É construído um prompt que combina uma determinada query com as melhores passagens de documentos do corpus, escolhidas através da classificação do BM25, e este é passado para o modelo, que gera uma resposta com base no contexto providenciado.

Question: Who founded Pixar?

Answer : George Lucas
 Sources: ['Thomas Edison', 'George Lucas', 'Pixar']

Question: What year did Technicolor become popular?

Answer : 1939
 Sources: ['History of animation', 'Casablanca (film)', 'The Jazz Singer']

Question: Which film pioneered German Expressionism?

Answer : the birth of a nation
 Sources: ['D. W. Griffith', 'Silent film', 'Harold Lloyd']

Question: What caused the decline of the studio system?

Answer : war damage
 Sources: ['RKO Pictures', '3D film', 'Cinema of the United States']

Question: Which film is associated with the Rashomon effect?

Answer : taurus
 Sources: ['3D film', 'History of film', 'History of film']

5 Conclusões

Ao analisar os resultados obtidos pelos diferentes tipos de extração de informação, podemos retirar algumas conclusões relativamente aos pontos fortes e fracos de cada uma, assim como ponderar novos métodos de preparação dos dados e estruturação da *pipeline* desenvolvida. O BM25 performou bastante bem, apresentando resultados coesos e acima de tudo, verdadeiros na sua maioria, à semelhança do SBERT na extração semântica, que não só mostrou ser efetivo, como também demonstrou uma grande melhoria quando comparamos a sua versão fine-tuned para o nosso problema, com a versão base. Os resultados do SBERT são ligeiramente surpreendente, já que o método escolhido para o scoring dos pares de documentos para o treino foi um pouco infeliz, dado o seu significado real e a quantidade limitada de informação que revela sobre o grau de semelhança de dois textos. O ponto mais fraco seria realmente o QA extrativo, que omite uma

grande parte das respostas devido à sua elevada literalidade, e tendo em conta que está dependente do contexto fornecido pelo passage retrieval. Já o abstractive QA apresenta resposta à maioria das questões, mas apesar de fazerem sentido de um ponto de vista lógico e semântico, a maior parte das vezes são simplesmente alucinadas e não correspondem à realidade.